

Roadmap plan cho bài tập lớn Data Mining (Kaggle competition)

Đề tài: Phân loại paper nghiên cứu ASP và các lĩnh vực liên quan

Mục tiêu: Tối ưu **Macro F1-score** trên Kaggle đồng thời có quy trình làm việc rõ ràng, có thể giải thích được trong báo cáo/thuyết trình.

1) Tóm tắt bài toán

Nhóm cần xây dựng mô hình dự đoán **Label** cho từng paper dựa trên dữ liệu metadata và text.

Theo file thực tế nhóm đang có ở stage 1:

- **Train:** 510 mẫu
- **Test:** 86 mẫu
- **Cột hiện có:** `title, venue, year, authors, doi, Label, id`
- **Lưu ý quan trọng:** file thực tế **không có** `abstract`, nhưng lại có `doi`
- **Thiếu dữ liệu:** `authors` bị thiếu một phần
- **Metric: Macro F1-score** → cần quan tâm cân bằng giữa các lớp, không chỉ accuracy

Nhận định nhanh từ dữ liệu hiện tại

- Số lớp: **5**
 - Phân bố label tương đối lệch nhẹ, chưa quá nặng:
 - Label 1: 130
 - Label 2: 103
 - Label 3: 85
 - Label 4: 89
 - Label 5: 103
 - `venue` hiện có 2 giá trị chính: `iclp, kr`
 - Dataset nhỏ → rất phù hợp với:
 - TF-IDF + model tuyến tính / boosting
 - Feature engineering từ metadata
 - Stacking / soft voting
 - Cross-validation cẩn thận để tránh overfit leaderboard
-

2) Mục tiêu kỹ thuật của nhóm

Mục tiêu bắt buộc

1. Có pipeline sạch, reproducible
2. Có ít nhất **3 baseline mạnh**
3. Có **cross-validation chuẩn theo Macro F1**
4. Có ít nhất **1 mô hình kết hợp text + metadata**
5. Có file submit đúng format
6. Có báo cáo giải thích rõ:
 - chọn feature nào
 - tại sao chọn model đó
 - so sánh các thử nghiệm
 - phân tích lỗi

Mục tiêu điểm số

- **Ngưỡng an toàn:** baseline chạy ổn, không lỗi, CV hợp lý
 - **Ngưỡng tốt:** có tuning + ensemble + error analysis
 - **Ngưỡng rất tốt:** có nhiều nhánh mô hình, blending hợp lý, báo cáo chặt chẽ, thuyết trình rõ insight
-

3) Chiến lược tổng thể để đạt kết quả tốt nhất

Vì dataset nhỏ và metric là Macro F1, chiến lược nên đi theo hướng:

1. **Làm thật chắc EDA và validation trước**
2. **Xây baseline nhanh** để có mốc so sánh
3. **Tách 3 nhánh feature**
 - Nhánh A: text từ `title`
 - Nhánh B: metadata (`venue` , `year` , `authors` , `doi`)
 - Nhánh C: hybrid = text + metadata
4. **Thử nhiều model cổ điển nhưng mạnh cho text nhỏ**
 - Logistic Regression
 - Linear SVM
 - Naive Bayes
 - Random Forest / XGBoost / LightGBM / CatBoost (nếu encode hợp lý)
5. **Tối ưu Macro F1 bằng cross-validation phân tầng**
6. **Error analysis theo từng lớp**
7. **Ensemble/blending** thay vì phụ thuộc 1 mô hình duy nhất

8. **Giữ log thí nghiệm** để tránh làm lại, tránh “cảm giác model tốt”

4) Phân chia vai trò cho 4 thành viên

Để tránh chồng chéo, mỗi người có **1 vai trò chính** và **1 vai trò phụ**.

Thành viên 1 – Project Lead + Validation Owner

Vai trò chính

- Quản lý tiến độ
- Thiết kế pipeline chung
- Chịu trách nhiệm validation và rule nộp Kaggle

Nhiệm vụ chính

- Tạo repo / folder structure
- Quy định cách đặt tên notebook, file submit, file log
- Thiết kế `StratifiedKFold` cho Macro F1
- Kiểm tra data leakage, duplicate, split strategy
- Tổng hợp kết quả từ mọi người
- Chọn final ensemble để submit

Vai trò phụ

- Review code và merge branch
- Chuẩn hóa format báo cáo/thuyết trình

Deliverables

- `README.md`
 - `configs/`
 - `cv_strategy.md`
 - bảng tổng hợp experiment
 - final submission shortlist
-

Thành viên 2 – EDA + Data Cleaning + Metadata Features

Vai trò chính

- Phân tích dữ liệu

- Xử lý dữ liệu thiếu, chuẩn hóa metadata
- Tạo feature từ `authors` , `venue` , `year` , `doi`

Nhiệm vụ chính

- Kiểm tra missing values, duplicates, outliers
- Phân tích phân bố label
- Phân tích title length, số author, năm xuất bản
- Chuẩn hóa `authors` :
 - số lượng tác giả
 - author xuất hiện nhiều
 - first author / last author
- Feature từ `doi` :
 - publisher prefix
 - pattern journal/conference
 - độ dài DOI
- Encode `venue` , `year bin` , `author_count`
- Làm báo cáo EDA có biểu đồ và insight

Vai trò phụ

- Hỗ trợ Member 3/4 ghép metadata vào pipeline model

Deliverables

- `notebooks/eda.ipynb`
 - `src/features_metadata.py`
 - `reports/eda_summary.md`
-

Thành viên 3 – Text Modeling Owner

Vai trò chính

- Xử lý text và xây các model baseline / advanced cho `title`

Nhiệm vụ chính

- Tiền xử lý `title`
 - lowercase
 - giữ/bỏ punctuation có kiểm chứng
 - stopwords thử nghiệm
 - stemming/lemmatization nếu cần
- Tạo vectorizer:

- word-level TF-IDF
- char-level TF-IDF
- word + char combined
- n-gram (1,2), (1,3), char 3-5
- Huấn luyện baseline:
 - Multinomial Naive Bayes
 - Logistic Regression
 - Linear SVM
- Tuning:
 - max_features
 - min_df / max_df
 - n-gram range
 - class_weight

Vai trò phụ

- Phối hợp với Member 4 để stacking/blending

Deliverables

- `notebooks/text_baselines.ipynb`
 - `src/text_pipeline.py`
 - bảng kết quả CV của từng text model
-

Thành viên 4 – Advanced Modeling + Ensemble + Reporting Support

Vai trò chính

- Xây mô hình nâng cao
- Ensemble / stacking / blending
- Hỗ trợ làm submission cuối

Nhiệm vụ chính

- Thử hybrid model:
 - TF-IDF title + metadata
 - FeatureUnion / ColumnTransformer
- Thử tree/boosting nếu hợp lý:
 - LightGBM / XGBoost / CatBoost
- Thử pseudo-labeling **nếu và chỉ nếu** CV ổn định
- Thử ensemble:
 - soft voting
 - weighted voting

- stacking level-2
- Phân tích confusion matrix
- Tổng hợp feature importance / top n-grams / lỗi theo lớp

Vai trò phụ

- Hỗ trợ dựng slide, bảng so sánh final

Deliverables

- `notebooks/hybrid_ensemble.ipynb`
- `src/ensemble.py`
- `reports/error_analysis.md`
- 2-3 final submission files

5) Cách phối hợp giữa 4 thành viên

Quy tắc chung

- Mỗi người làm trên **1 branch riêng**
- Mọi kết quả đều phải ghi vào **bảng experiment chung**
- Không dùng leaderboard làm tiêu chuẩn duy nhất
- Quyết định cuối dựa trên:
 1. CV Macro F1
 2. độ ổn định qua folds
 3. tính hợp lý của mô hình
 4. leaderboard chỉ dùng để tham khảo

Bảng log thí nghiệm nên có

Run ID	Người phụ trách	Feature set	Model	CV Macro F1	Std	Public LB	Ghi chú
exp_001	M3	TF-IDF title word(1,2)	Logistic Regression	0.xxx	0.xxx	0.xxx	baseline
exp_002	M2	metadata only	CatBoost	0.xxx	0.xxx	0.xxx	venue mạnh
exp_003	M4	title + metadata	Linear SVM	0.xxx	0.xxx	0.xxx	hybrid

6) Roadmap chi tiết theo giai đoạn

Có thể triển khai trong **10 ngày**. Nếu nhóm ít thời gian, có thể nén xuống **7 ngày** bằng cách rút bớt tuning và ensemble.

Giai đoạn 1 – Khởi động dự án (Ngày 1)

Mục tiêu

- Hiểu dữ liệu
- Chia việc rõ
- Định khung dự án

Việc cần làm

Member 1

- Tạo repo GitHub / Drive folder
- Tạo cấu trúc thư mục
- Tạo template experiment tracker
- Tạo baseline split bằng `StratifiedKFold`

Member 2

- Chạy EDA ban đầu
- Kiểm tra missing, duplicate, class balance

Member 3

- Viết notebook baseline đọc data + TF-IDF title

Member 4

- Chuẩn bị notebook evaluation + confusion matrix + submit generator

Deliverables cuối ngày

- Repo chạy được
 - Cả nhóm đọc được data
 - Có EDA sơ bộ
 - Có kế hoạch branch và naming
-

Giai đoạn 2 – Data audit & feature hypotheses (Ngày 2)

Mục tiêu

Tìm ra các feature đáng thử trước khi model hóa nặng.

Việc cần làm

Member 2 lead

- Phân tích:
 - label vs venue
 - label vs year
 - label vs title length
 - label vs author count
 - pattern DOI
- Xem title của từng lớp có từ khóa đặc trưng gì

Member 1 support

- Kiểm tra duplicate title/doi
- Xác định có cần deduplicate hay giữ nguyên

Member 3 support

- Xuất top n-grams theo label

Member 4 support

- Chuẩn hóa hàm đánh giá Macro F1

Deliverables cuối ngày

- File `eda_summary.md`
 - Danh sách feature hypothesis:
 - venue có thể predictive
 - year có thể phản ánh xu hướng
 - authors/doi có tín hiệu phụ
 - title là feature chính
-

Giai đoạn 3 – Baseline nhanh và chắc (Ngày 3–4)

Mục tiêu

Có ít nhất 3 baseline tốt, làm mốc để cải tiến.

Việc cần làm

Member 3 lead

Chạy các baseline text:

1. TF-IDF word unigram + Logistic Regression
2. TF-IDF word (1,2) + Linear SVM
3. TF-IDF char (3,5) + Logistic Regression
4. TF-IDF word + char combined

Member 2 lead song song

Chạy baseline metadata:

1. venue + year + author_count

2. venue + year + doi features

3. CatBoost / Logistic Regression / Random Forest cho metadata-only

Member 1

- Chuẩn hóa cách ghi kết quả CV
- Kiểm tra fold variance
- So sánh fairness giữa các run

Member 4

- Tạo pipeline feature union
- Chuẩn bị hybrid baseline

Deliverables cuối ngày 4

- Bảng so sánh baseline đầy đủ
 - Chọn ra:
 - best text-only
 - best metadata-only
 - 1 candidate hybrid
-

Giai đoạn 4 – Hybrid modeling & tuning (Ngày 5–6)

Mục tiêu

Đẩy điểm số bằng cách kết hợp feature và tuning có kiểm soát.

Việc cần làm

Member 4 lead

- Kết hợp:
 - TF-IDF title + OneHot venue + numeric year + author_count + doi stats

- Thử:
 - Logistic Regression
 - Linear SVM
 - LightGBM/CatBoost trên feature phù hợp
- Tuning:
 - regularization
 - class_weight
 - max_features
 - ngram_range

Member 3

- Tuning vectorizer:
 - min_df
 - max_df
 - analyzer
 - sublinear_tf
- So sánh word vs char vs word+char

Member 2

- Thêm feature:
 - first author frequency
 - authors hash / rare-author indicator
 - year bucket
 - DOI prefix category

Member 1

- Theo dõi xem tuning nào có cải thiện thực sự
- Loại bỏ run “ảo” do variance cao

Deliverables cuối ngày 6

- 2-3 model tốt nhất theo CV
 - Bảng tuning có lý do chọn
-

Giai đoạn 5 – Error analysis & class-focused improvement (Ngày 7)

Mục tiêu

Tăng Macro F1 bằng cách tập trung vào lớp khó.

Việc cần làm

Member 4 lead

- Vẽ confusion matrix
- Xem lớp nào bị nhầm nhiều nhất
- Tính F1 theo từng lớp

Member 3

- Trích các title bị đoán sai
- Xem mô hình text đang nhầm ở đâu:
 - title quá ngắn
 - từ khóa chồng lấn giữa lớp
 - venue áp đảo dự đoán

Member 2

- So lại metadata của các mẫu đoán sai
- Kiểm tra missing authors có làm model lệch không

Member 1

- Tổ chức họp nhóm 30–45 phút chốt hướng cải thiện cuối

Deliverables cuối ngày

- `error_analysis.md`
- Danh sách hành động:

- tăng trọng số lớp nào?
 - dùng ensemble không?
 - loại feature nào gây nhiễu?
-

Giai đoạn 6 – Ensemble & final submission

(Ngày 8–9)

Mục tiêu

Tạo submission cuối đủ mạnh và ổn định.

Việc cần làm

Member 4 lead

- Ensemble 2–4 model tốt nhất:
 - soft voting
 - weighted voting
 - stacking đơn giản
- So sánh CV trước/sau ensemble

Member 1

- Chọn final candidates để submit
- Quản lý version submission:
 - `sub_v1_baseline.csv`
 - `sub_v2_hybrid.csv`
 - `sub_v3_ensemble.csv`

Member 3

- Kiểm tra consistency pipeline train/test
- Tránh mismatch vocabulary

Member 2

- Kiểm tra format file submit
- Audit lại missing / encoding / id mapping

Deliverables cuối ngày 9

- 2-3 submission cuối
 - Bảng lý do chọn final submission
 - File final dùng để nộp Kaggle
-

Giai đoạn 7 – Báo cáo & thuyết trình (Ngày 10)

Mục tiêu

Biến quá trình làm thành câu chuyện chặt chẽ, thuyết phục.

Việc cần làm

Member 1 lead

- Dàn khung báo cáo
- Phân công ai nói phần nào

Member 2

- Viết phần dataset understanding + EDA + metadata features

Member 3

- Viết phần text representation + baseline + tuning

Member 4

- Viết phần hybrid model + ensemble + error analysis + final result

Cấu trúc báo cáo gợi ý

1. Giới thiệu bài toán
2. Mô tả dữ liệu
3. EDA và insight
4. Tiền xử lý
5. Feature engineering
6. Mô hình thử nghiệm
7. Validation strategy
8. Kết quả
9. Error analysis
10. Kết luận và hướng cải thiện

Deliverables cuối cùng

- Báo cáo hoàn chỉnh
 - Slide
 - Notebook sạch
 - Final submission
 - Repo có thể chạy lại
-

7) Backlog kỹ thuật chi tiết cần ưu tiên

Mức ưu tiên cao (phải làm)

- ☐ StratifiedKFold + Macro F1 scorer
- ☐ TF-IDF word-level baseline
- ☐ TF-IDF char-level baseline
- ☐ Metadata features cơ bản
- ☐ Hybrid model
- ☐ Confusion matrix
- ☐ File submit đúng format

Mức ưu tiên trung bình (nên làm)

- ☐ DOI parsing
- ☐ author_count, rare_author features
- ☐ class_weight tuning
- ☐ weighted voting ensemble
- ☐ calibration hoặc threshold check nếu cần

Mức ưu tiên nâng cao (chỉ làm khi đã ổn)

- ☐ pseudo-labeling
 - ☐ stacking level-2
 - ☐ pretrained text embedding
 - ☐ sentence transformer cho title
 - ☐ domain keyword lexicon feature
-

8) Đề xuất pipeline mô hình theo thứ tự thử nghiệm

Baseline 1

- Input: `title`
- Feature: TF-IDF word unigram/bigram
- Model: Logistic Regression
- Mục tiêu: baseline ổn định, nhanh

Baseline 2

- Input: `title`
- Feature: TF-IDF char 3-5 grams
- Model: Linear SVM
- Mục tiêu: bắt pattern từ thuật ngữ học thuật, acronym, tên phương pháp

Baseline 3

- Input: `venue`, `year`, `authors`, `doi`
- Feature: one-hot + numeric + handcrafted
- Model: CatBoost / Logistic Regression
- Mục tiêu: đo tín hiệu từ metadata

Strong candidate 1

- Input: title + metadata
- Feature: ColumnTransformer (TF-IDF + OneHot + numeric)
- Model: Linear SVM / Logistic Regression

Strong candidate 2

- Input: title + metadata
- Feature: word TF-IDF + char TF-IDF + metadata
- Model: ensemble

Final candidate

- Blend:
 - best text-only
 - best hybrid
 - best metadata-augmented model
-

9) Chuẩn kỹ thuật bắt buộc để tránh mất điểm oan

- Luôn fix `random_state`
 - Luôn dùng cùng một CV split để so sánh model
 - Không nhìn leaderboard quá nhiều để tránh overfit public LB
 - Không đưa `Label` hay biến rò rỉ vào feature
 - Khi join feature train/test phải đảm bảo cột khớp
 - Kiểm tra submit:
 - đúng số dòng
 - đúng thứ tự `id`
 - cột tên chính xác: `id, Label`
 - Ghi lại mọi thí nghiệm vào bảng log
 - Notebook final phải chạy từ đầu đến cuối
-

10) Rủi ro chính và cách xử lý

Rủi ro 1: Dataset nhỏ → kết quả dao động

Cách xử lý

- Dùng Stratified K-Fold
- Báo cáo mean + std
- Không kết luận chỉ từ 1 split

Rủi ro 2: Overfit leaderboard

Cách xử lý

- Chọn model theo CV
- Chỉ submit các candidate thực sự khác nhau

Rủi ro 3: Chống chéo công việc nhóm

Cách xử lý

- Mỗi người có deliverable rõ
- Có experiment sheet chung
- Họp ngắn mỗi ngày 10–15 phút

Rủi ro 4: Code không ghép được

Cách xử lý

- Thống nhất path, naming, environment từ ngày đầu
- Dùng `requirements.txt`

Rủi ro 5: Metadata gây nhiễu

Cách xử lý

- Luôn so sánh với text-only baseline
 - Chỉ giữ feature nào cải thiện CV
-

11) Lịch họp nhóm đề xuất

Họp 1 – Kickoff (Ngày 1)

- Chốt vai trò
- Chốt cấu trúc repo
- Chốt metric + validation

Họp 2 – Sau baseline (Ngày 4)

- Xem baseline nào mạnh
- Quyết định hướng tuning

Họp 3 – Sau error analysis (Ngày 7)

- Chốt final model strategy
- Chia việc làm báo cáo

Họp 4 – Trước khi nộp (Ngày 10)

- Review submit
 - Review slide/báo cáo
 - Kiểm tra lần cuối format
-

12) Cấu trúc thư mục đề xuất

```
project/
|
├── data/
|   ├── raw/
|   ├── processed/
|   └── submissions/
|
├── notebooks/
|   ├── 01_eda.ipynb
|   ├── 02_text_baseline.ipynb
|   ├── 03_metadata_features.ipynb
|   ├── 04_hybrid_models.ipynb
|   └── 05_ensemble_error_analysis.ipynb
|
├── src/
|   ├── utils.py
|   ├── metrics.py
|   ├── preprocess.py
|   ├── features_metadata.py
|   ├── text_pipeline.py
|   └── ensemble.py
|
├── reports/
|   ├── eda_summary.md
|   ├── error_analysis.md
|   └── final_report.md
|
├── configs/
|   └── experiment_config.yaml
|
```

13) Definition of Done

Nhóm được xem là hoàn thành tốt nếu đạt đủ các điều kiện sau:

- ☐ Có EDA và insight rõ ràng
 - ☐ Có ít nhất 3 baseline được so sánh công bằng
 - ☐ Có validation chuẩn bằng Macro F1
 - ☐ Có ít nhất 1 mô hình hybrid
 - ☐ Có error analysis theo lớp
 - ☐ Có ensemble hoặc lý do rõ vì sao không ensemble
 - ☐ Có submission cuối đúng format
 - ☐ Có báo cáo giải thích logic, không chỉ đưa điểm số
-

14) Kết luận chiến lược ngắn gọn

Để đạt kết quả tốt nhất, nhóm nên đi theo hướng:

1. **Làm chắc validation**
 2. **Xây baseline text thật mạnh**
 3. **Khai thác metadata thông minh nhưng không lạm dụng**
 4. **Dùng hybrid model**
 5. **Phân tích lỗi để cải thiện Macro F1**
 6. **Dùng ensemble ở giai đoạn cuối**
 7. **Ghi log đầy đủ để báo cáo/thuyết trình thuyết phục**
-

15) Phân công ngắn gọn để bắt đầu ngay hôm nay

Member 1

- Setup repo, CV strategy, experiment tracker, merge kết quả

Member 2

- EDA, data cleaning, metadata features, insight report

Member 3

- TF-IDF + text baselines + tuning

Member 4

- Hybrid models, ensemble, error analysis, final submission support
-

Khuyến nghị cuối:

Nếu thời gian có hạn, hãy ưu tiên theo thứ tự:

1. text baseline
2. hybrid text + metadata
3. error analysis
4. ensemble
5. báo cáo sạch và có lý do rõ ràng

Với dataset nhỏ như stage 1, một pipeline **TF-IDF tốt + Linear model tốt + metadata vừa đủ + ensemble gọn** thường sẽ là hướng có tỷ lệ hiệu quả / công sức rất cao.